

**Universidade Federal de Santa Maria**

**Centro de Tecnologia**

**Curso de Ciência da Computação**

## **Trabalho Prático: Redes Neurais Artificiais**

Pipeline de Machine Learning para Predição e Análise de Diabetes

**Disciplina:** Inteligência Artificial

**Acadêmicos:**

Lucas Xavier Pairé

Miguel Brondani

Santa Maria, RS

24 de junho de 2026

# Sumário

|          |                                                                   |           |
|----------|-------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                                 | <b>2</b>  |
| <b>2</b> | <b>Etapa 1 - Escolha e Análise do Dataset</b>                     | <b>2</b>  |
| 2.1      | Características Estruturais . . . . .                             | 2         |
| 2.2      | Distribuição de Classes e Problemas Identificados . . . . .       | 2         |
| <b>3</b> | <b>Etapa 2 - Pré-processamento</b>                                | <b>3</b>  |
| 3.1      | Amostragem Estratificada . . . . .                                | 3         |
| 3.2      | Divisão em Treino e Teste (Holdout) . . . . .                     | 3         |
| 3.3      | Padronização de Atributos . . . . .                               | 4         |
| <b>4</b> | <b>Etapa 3 - Seleção de Atributos (Feature Selection)</b>         | <b>4</b>  |
| <b>5</b> | <b>Etapa 4 - Classificação com MLP</b>                            | <b>4</b>  |
| 5.1      | Classificação Binária . . . . .                                   | 4         |
| 5.2      | Classificação Multiclasse . . . . .                               | 6         |
| <b>6</b> | <b>Etapa 5 - Regressão com MLP</b>                                | <b>7</b>  |
| 6.1      | Configuração da Meta Contínua . . . . .                           | 7         |
| 6.2      | Resultados e Análise Crítica . . . . .                            | 7         |
| <b>7</b> | <b>Etapa 6 - Otimização de Hiperparâmetros</b>                    | <b>8</b>  |
| 7.1      | Estratégia do Espaço de Busca e Função Objetivo . . . . .         | 8         |
| 7.2      | Tabela Comparativa Geral do Pipeline . . . . .                    | 9         |
| 7.3      | Análise Crítica dos Baixos Valores de F1-Score e Recall . . . . . | 9         |
| <b>8</b> | <b>Etapa 7 - Regularização</b>                                    | <b>10</b> |
| 8.1      | Técnica Utilizada e Configuração . . . . .                        | 10        |
| 8.2      | Discussão dos Resultados . . . . .                                | 11        |
| <b>9</b> | <b>Conclusão</b>                                                  | <b>12</b> |

# 1 Introdução

Este relatório apresenta o desenvolvimento de um pipeline de Machine Learning para a predição de Diabetes Mellitus utilizando o dataset *Diabetes Health Indicators* (BRFSS 2015 do CDC). O trabalho aborda classificação binária, classificação multiclasse e regressão usando redes neurais do tipo *Multi-Layer Perceptron* (MLP). Foram aplicadas técnicas de amostragem estratificada, seleção de atributos por Informação Mútua (*Mutual Information*), otimização de hiperparâmetros com o *Optuna* e regularização por *Early Stopping*. A análise foca nos impactos do desbalanceamento de classes nas métricas de avaliação e nos efeitos da redução de dimensionalidade no desempenho dos modelos.

## 2 Etapa 1 - Escolha e Análise do Dataset

O dataset escolhido é o **Diabetes Health Indicators Dataset**, obtido no Kaggle. Os dados vêm do *Behavioral Risk Factor Surveillance System* (BRFSS) de 2015, uma pesquisa telefônica realizada anualmente pelo CDC dos Estados Unidos. O conjunto foi selecionado por conter registros sobre fatores socioeconômicos e comportamentais associados ao diabetes, sendo bastante utilizado na literatura da área.

### 2.1 Características Estruturais

O arquivo original (*diabetes\_binary\_health\_indicators\_BRFSS2015.csv*) possui as seguintes especificações dimensionais primárias:

- **Quantidade Total de Amostras:** 253.680 registros estruturados.
- **Quantidade de Atributos Preditivos (Features):** 21 variáveis explicativas.
- **Variável Alvo (Target):** *Diabetes\_binary*, indicando se o indivíduo é saudável (0.0) ou se possui diagnóstico prévio de diabetes ou pré-diabetes (1.0).

### 2.2 Distribuição de Classes e Problemas Identificados

A análise exploratória de dados revelou alguns pontos importantes que exigiram tratamento posterior:

- **Desbalanceamento de Classes:** A variável alvo é muito desbalanceada: 86,06% das amostras pertencem à classe 0 (saudável) e 13,94% à classe 1 (diabetes). Essa assimetria pode fazer com que o classificador priorize a classe majoritária.
- **Valores Ausentes e Outliers:** Não há dados ausentes no dataset. Como a maioria das colunas representa respostas discretas ou ordinais, a presença de outliers numéricos restringe-se à variável de IMC (BMI).

- **Duplicidade de Registros:** Foram identificadas 24.206 linhas duplicadas. Apesar de respostas idênticas serem possíveis em pesquisas de larga escala, optou-se pela remoção dessas duplicatas.
- **Correlação Elevada:** A correlação de Pearson (Figura 1) mostrou uma correlação linear baixa entre as variáveis de entrada e o alvo, o que justifica o uso de modelos capazes de capturar relações não-lineares, como as redes neurais.




Figura 1: Matriz de Correlação Linear de Pearson para os atributos do dataset.

## 3 Etapa 2 - Pré-processamento

Para treinar as redes MLP de forma eficiente, aplicou-se o seguinte fluxo de pré-processamento:

### 3.1 Amostragem Estratificada

Dado o tamanho do dataset (253.680 registros), o processo de treinamento repetido para busca de hiperparâmetros seria demorado. Assim, extraímos uma subamostra estratificada de 20% do total (50.736 linhas). A estratificação manteve a proporção original de 86,06% para a classe 0 e 13,94% para a classe 1.

### 3.2 Divisão em Treino e Teste (Holdout)

A subamostra foi dividida em:

- **80% para Treinamento:** Usado no ajuste de pesos da rede.
- **20% para Teste:** Reservado para a avaliação final do modelo com dados novos.

### 3.3 Padronização de Atributos

Como os algoritmos baseados em descida de gradiente são sensíveis à escala das variáveis, aplicou-se a padronização Z-score (**StandardScaler**) nas entradas. Isso transforma as features para terem média zero e variância unitária, evitando que atributos com valores maiores (como **BMI**) dominem o gradiente sobre atributos binários (como **Smoker**). O scaler foi ajustado no conjunto de treino e aplicado no teste para evitar vazamento de dados (*data leakage*).

## 4 Etapa 3 - Seleção de Atributos (Feature Selection)

Para reduzir o custo computacional e mitigar overfitting, aplicamos a seleção de atributos via **Informação Mútua (Mutual Information)**. Esse método avalia a relevância das variáveis independentemente do algoritmo de aprendizado.

A Informação Mútua mede a quantidade de informação compartilhada entre duas variáveis usando a Entropia de Shannon. Diferente do coeficiente de Pearson, ela consegue capturar dependências não-lineares, o que é útil para redes neurais.

Definimos um corte para selecionar os **10 atributos com maior relevância**. Variáveis como percepção geral de saúde (**GenHlth**), Pressão Alta (**HighBP**), Colesterol Elevado (**HighChol**) e Índice de Massa Corporal (**BMI**) ficaram no topo do ranking, condizendo com os principais fatores de risco conhecidos para o diabetes.

## 5 Etapa 4 - Classificação com MLP

### 5.1 Classificação Binária

Como modelo *baseline*, configuramos uma rede **MLPClassifier** com hiperparâmetros iniciais fixos:

- **Arquitetura das Camadas Ocultas:** Duas camadas densas dispostas em formato piramidal com (64, 32) neurônios, respectivamente. Esta escolha justifica-se pela busca de extrair abstrações não-lineares progressivas a partir das variáveis de entrada. O design em formato de pirâmide (reduzindo a dimensão da camada 1 para a 2) atua como um compressor de características antes da camada de saída. Além disso, o número de neurônios (totalizando aproximadamente 3.000 parâmetros ajustáveis) previne o sobreajuste em relação ao tamanho da amostra, mantendo capacidade representativa.
- **Função de Ativação:** Unidade Linear Retificada (**relu**), minimizando o problema de desvanecimento do gradiente e acelerando o treino.


- **Algoritmo Otimizador:** adam, devido ao cálculo computacional adaptativo de taxas de aprendizado.
- **Tamanho do Lote (Batch Size):** 128 instâncias por iteração.
- **Limitação de Épocas:** max\_iter=150 iterações de salvaguarda.
- **Regularização Prematura:** Desativada temporariamente (early\_stopping=False).

O experimento consistiu em comparar dois cenários:

1. **Cenário A (Todas as Features):** Alimentado com todos os 21 atributos originais.
2. **Cenário B (Features Seleccionadas):** Alimentado apenas com o subconjunto de 10 atributos via Informação Mútua.


As matrizes de confusão obtidas nos testes para ambos os cenários estão na Figura 2. As métricas detalhadas são comparadas na Tabela 1 na Etapa 6.

Matriz de Confusão - Todas\_as\_Features\_Hiper\_Ran



(a) Cenário A - Todas as Features

Matriz de Confusão - Features\_Seleccionadas\_Hiper\_R



(b) Cenário B - Features Seleccionadas

Figura 2: Matrizes de Confusão para a MLP de Classificação Binária Baseline.




Figura 3: Evolução da Acurácia de Validação por Época para os modelos baseline binários (Cenários A e B).

A Figura 3 apresenta a evolução da acurácia de validação ao longo das épocas de treinamento para os dois cenários. Em ambos os casos, a acurácia de validação sobe rapidamente nas primeiras épocas e se estabiliza em valores próximos a 84–85%, confirmando a convergência dos modelos dentro do limite de 150 iterações. A estabilidade da curva ao longo das últimas épocas indica que o modelo não se beneficiaria de um treinamento mais longo sem ajustes adicionais de hiperparâmetros.


## 5.2 Classificação Multiclasse

Para estender a análise, avaliamos a classificação de 3 classes usando o arquivo *diabetes\_012\_health\_indicators\_BRFSS2015.csv*, onde a variável alvo `Diabetes_012` indica se o indivíduo é saudável (0.0), pré-diabético (1.0) ou diabético (2.0).


O pré-processamento (holdout 80/20, amostragem de 20% e padronização) e os 10 atributos de entrada foram mantidos. A `MLPClassifier` foi configurada com a mesma estrutura de camadas (64, 32), ativação `relu` e otimizador `adam`.

A avaliação do modelo nos dados de teste gerou as seguintes métricas macro-ponderadas:

- **Acurácia Global:** 0,8353
- **Precisão Macro:** 0,4730
- **Recall Macro:** 0,3814
- **F1-Score Macro:** 0,3882



(a) Matriz de Confusão Multiclasse



(b) Curva de Aprendizado (Multiclasse)

Figura 4: Resultados obtidos para a MLP na tarefa de Classificação Multiclasse.

A análise da matriz de confusão (Figura 4a) revela que o modelo apresenta grande facilidade para classificar corretamente indivíduos saudáveis (Classe 0), porém exibe dificuldades agudas na identificação das classes 1 (pré-diabetes) e 2 (diabetes). Essa dificuldade é explicada pelo desbalanceamento severo das classes: a classe 1 representa uma fração

extremamente ínfima do conjunto de dados original (cerca de 1,8%), fazendo com que o classificador praticamente ignore essa classe em suas previsões e a confunda constantemente com as classes adjacentes. Isso prejudica o *Recall* e a *Precisão* macro-ponderados. A curva de perda (Figura 4b) aponta uma convergência estável da rede até o limite de 150 épocas.

## 6 Etapa 5 - Regressão com MLP

Adaptamos o pipeline para uma tarefa de regressão usando a classe `MLPRegressor`.

### 6.1 Configuração da Meta Contínua

A variável contínua BMI (**Índice de Massa Corporal**) foi removida do conjunto de entradas e redefinida como a nova variável alvo numérica contínua ( $y_{reg}$ ). O objetivo da rede neural passou a ser a estimativa exata do IMC de um indivíduo a partir de seus demais hábitos comportamentais e indicadores clínicos (excluindo a coluna `Diabetes_binary`). Para manter o alinhamento com a Etapa 3, o regressor foi alimentado utilizando o ranking de atributos selecionados (excetuando o próprio alvo). Os parâmetros estruturais de camadas ocultas (64, 32), otimizador `adam`, ativação `relu` e `batch_size=128` foram preservados de forma intencional para manter a consistência metodológica, permitindo uma comparação direta da capacidade de generalização e do comportamento de aprendizado da mesma arquitetura de rede neural em tarefas de natureza distinta (classificação vs. regressão).

### 6.2 Resultados e Análise Crítica

A avaliação do regressor em dados de teste inéditos gerou os seguintes resultados numéricos estáveis:

- **Erro Médio Absoluto (MAE):** 4,4532
- **Erro Quadrático Médio (MSE):** 40,9024
- **Raiz do Erro Quadrático Médio (RMSE):** 6,3955
- **Coefficiente de Determinação ( $R^2$  Score):** 0,1182

O comportamento do regressor (valores reais vs. preditos e a distribuição dos resíduos) está plotado graficamente na Figura 5. A análise das métricas indica que, em média, as estimativas da MLP desviam-se por aproximadamente 4,45 pontos de IMC. O fato de o RMSE (6,3955) apresentar-se superior ao MAE (4,4532) mostra que o modelo comete erros



de maior magnitude nas caudas da distribuição, demonstrando dificuldade para prever o IMC de indivíduos em extremos de peso.

O coeficiente  $R^2 = 0,1182$  indica que as features de saúde disponíveis explicam apenas 11,82% da variabilidade total do IMC. Isso reflete a complexidade do problema: fatores biológicos e comportamentais cruciais para a definição do IMC, tais como a taxa metabólica basal, o consumo calórico preciso e rotinas específicas de atividade física, não estão presentes no questionário do BRFSS, limitando o desempenho final do modelo. A evolução convergente do erro de regressão pode ser monitorada no subgráfico correspondente.




Figura 5: Resultados gráficos obtidos na Etapa 5 (Regressão).

## 7 Etapa 6 - Otimização de Hiperparâmetros

Retornando ao escopo da Classificação Binária, utilizamos o framework **Optuna** para buscar melhores hiperparâmetros. O foco na classificação binária se deu pelas baixas taxas de Recall observadas nas redes baseline da Etapa 4, causadas pelo desbalanceamento.

### 7.1 Estratégia do Espaço de Busca e Função Objetivo

O Optuna utilizou amostragem bayesiana (algoritmo TPE) em 10 trials no seguinte espaço dinâmico:

- Neurônios na Camada Oculta 1: Inteiros entre 32 e 128 (passo de 32).
- Neurônios na Camada Oculta 2: Inteiros entre 16 e 64 (passo de 16).
- Função de Ativação: Alternância entre `relu` e `tanh`.
- Taxa de Aprendizado Inicial ( $\alpha$ ): Escala logarítmica contínua entre  $10^{-4}$  e  $10^{-2}$ .
- Tamanho do Lote (*Batch Size*): Escolha categórica entre [64, 128, 256].

A função objetivo buscou maximizar o F1-Score no conjunto de validação para forçar a rede a reduzir falsos negativos. Após os 10 trials, o **melhor F1-Score obtido na validação foi de 0,3144**. O conjunto de hiperparâmetros que maximizou essa métrica foi:

- **Neurônios na Camada 1:** 128
- **Neurônios na Camada 2:** 16
- **Função de Ativação:** tanh
- **Taxa de Aprendizado Inicial:** 0,007279
- **Tamanho do Lote:** 256

O classificador final otimizado foi reavaliado e sua matriz de confusão correspondente gerada (Figura 6).




Figura 6: Matriz de Confusão do modelo MLP Otimizado via Optuna.

## 7.2 Tabela Comparativa Geral do Pipeline

A Tabela 1 consolida o desempenho evolutivo observado ao longo do projeto para a classificação binária, incluindo os dados obtidos após a aplicação de regularização discutidos na seção seguinte.

Tabela 1: Métricas Comparativas de Desempenho (Classificação Binária).

| Cenário / Modelo                   | Accuracy | Precision | Recall   | F1-Score | ROC-AUC  |
|------------------------------------|----------|-----------|----------|----------|----------|
| Todas_as_Features_Hiper_Random     | 0,819261 | 0,377049  | 0,278490 | 0,320361 | 0,750299 |
| Features_Selecionadas_Hiper_Random | 0,844536 | 0,479574  | 0,192308 | 0,274530 | 0,775117 |
| MLP Otimizada (Optuna)             | 0,847587 | 0,505112  | 0,175926 | 0,260961 | 0,794098 |
| MLP Regularizada (Early Stopping)  | 0,850746 | 0,552469  | 0,127493 | 0,207176 | 0,802013 |

## 7.3 Análise Crítica dos Baixos Valores de F1-Score e Recall

A Tabela 1 mostra que, enquanto a acurácia é alta (entre 81,9% e 85,1%), as métricas que avaliam a classe positiva (Recall e F1-Score) são baixas.

Isso ocorre porque apenas 13,94% dos dados são positivos. O classificador tende a focar na classe majoritária para reduzir o erro global. Como consequência:

1. **A Ilusão da Acurácia:** Um modelo simples que apenas classificasse todos como saudáveis (classe 0) obteria cerca de 86% de acurácia. Por isso, os altos valores de acurácia observados não refletem eficácia clínica, mas sim o peso estatístico da classe majoritária.
2. **Subestimação do Recall (Sensibilidade):** O Recall variou entre 12,7% e 17,6% nos modelos otimizados e regularizados. Isso significa que a rede identifica apenas cerca de 1 em cada 6 ou 8 diabéticos, gerando muitos falsos negativos.
3. **A Queda Consequente do F1-Score:** Como o F1-Score é a média harmônica entre Precision e Recall, ele é puxado para baixo pelo baixo Recall, limitando-se ao teto de 0,2610 (atingido pelo Optuna).
4. **A Importância do ROC-AUC:** O ROC-AUC manteve-se estável, alcançando 0,8020 no modelo com Early Stopping. O ROC-AUC avalia a ordenação probabilística do classificador. O valor próximo a 0,80 indica que a rede aprendeu a ordenar bem as probabilidades, mas o limiar de decisão de 0,5 prejudica a classificação.

Para aplicações clínicas, contornar esses limites exigiria ajustar o threshold de decisão via curvas ROC, usar pesos nas classes (*class weights*) na função de perda, ou aplicar algoritmos de sobreamostragem (como o *SMOTE*).

## 8 Etapa 7 - Regularização

A etapa final consistiu na aplicação de técnicas de regularização, comparando o comportamento da rede com os cenários anteriores.

### 8.1 Técnica Utilizada e Configuração

A abordagem de regularização incorporada ao projeto foi o **Early Stopping (Parada Antecipada)**. O algoritmo separa 15% dos dados de treino para validação. Se a perda ou a acurácia de validação não melhorar por 10 épocas seguidas, o treino é interrompido para evitar overfitting.




Figura 7: Curvas de Aprendizado para os cenários Otimizado sem Regularização e com Early Stopping.

A Figura 7 ilustra os gráficos de monitoramento. Sem regularização, a perda de treino cai constantemente até o limite de épocas. Com Early Stopping, o treino é interrompido antes das 150 épocas quando a curva de validação (tracejado laranja) atinge estabilidade.

## 8.2 Discussão dos Resultados

A análise das curvas mostra que o treinamento convergiu de forma estável e que a Informação Mútua reduziu a complexidade, favorecendo a generalização.

No conjunto de teste, o modelo com Early Stopping teve um aumento de precisão, que subiu de 50,5% para **55,2%**, e de ROC-AUC, que chegou a **0,8020**. O Recall caiu para 12,7% (com F1 de 0,2072), mas o modelo final se mostrou mais robusto contra falsos positivos, indicando que a parada antecipada barrou ajustes espúrios.

### Análise de Overfitting e Underfitting

1. **A rede apresentou sinais de overfitting?** Sinais leves de overfitting foram observados no modelo sem regularização: a loss de treino continuava caindo enquanto a perda de validação estagnou, indicando que a rede começava a se ajustar aos dados de treino além do necessário. O Early Stopping suprimiu esse comportamento.
2. **Qual técnica de regularização foi utilizada?** Early Stopping (Parada Antecipada), com `validation_fraction=0.15` e `n_iter_no_change=10`.
3. **Houve melhoria no desempenho em dados não vistos?** Sim. A Precisão subiu de 50,5% para 55,2% e o ROC-AUC aumentou de 0,7941 para 0,8020, indicando melhor capacidade de generalização.
4. **Qual estratégia apresentou melhor equilíbrio entre desempenho e generalização?** A combinação de seleção de atributos por Informação Mútua, otimização de hiperparâmetros com Optuna e regularização por Early Stopping.

**Análise de Underfitting:** Os modelos não apresentaram sinais de underfitting. A curva de loss de treino converge de forma contínua e decrescente até estabilizar, sem platô

premature nas primeiras épocas. Ademais, as métricas de treino (especialmente o ROC-AUC) superaram consistentemente as de validação, comportamento característico de ajuste adequado e não de subajuste. A arquitetura (64,32) possui capacidade representativa suficiente para o tamanho e a complexidade do dataset BRFSS 2015.

Considerando os resultados, o melhor equilíbrio entre desempenho e generalização foi alcançado pela combinação de seleção de atributos por Informação Mútua, otimização de hiperparâmetros com Optuna e regularização por Early Stopping.

## 9 Conclusão

O pipeline desenvolvido cumpriu os requisitos propostos. O estudo confirmou que a acurácia isolada é insuficiente para problemas biomédicos desbalanceados e provou que o gerenciamento correto da dimensionalidade e o ajuste fino de parâmetros via Early Stopping e Optuna ajudam a obter redes neurais mais robustas e generalistas.