

Universidade Federal de Santa Maria

Centro de Tecnologia

Curso de Ciência da Computação

Trabalho Prático: Redes Neurais Artificiais

Pipeline de Machine Learning para Predição e Análise de Diabetes

Disciplina: Inteligência Artificial

Acadêmicos:

Lucas Xavier Pairé

Miguel Brondani

Santa Maria, RS

24 de junho de 2026

Sumário

1	Introdução	2
2	Etapa 1 - Escolha e Análise do Dataset	2
2.1	Características Estruturais	2
2.2	Distribuição de Classes e Problemas Identificados	2
3	Etapa 2 - Pré-processamento	3
3.1	Amostragem Estratificada	3
3.2	Divisão em Treino e Teste (Holdout)	3
3.3	Padronização de Atributos	4
4	Etapa 3 - Seleção de Atributos (Feature Selection)	4
5	Etapa 4 - Classificação com MLP	4
5.1	Classificação Binária	4
5.2	Classificação Multiclasse	6
6	Etapa 5 - Regressão com MLP	7
6.1	Configuração da Meta Contínua	7
6.2	Resultados e Análise Crítica	8
7	Etapa 6 - Otimização de Hiperparâmetros	8
7.1	Estratégia do Espaço de Busca e Função Objetivo	9
7.2	Tabela Comparativa Geral do Pipeline	10
7.3	Análise Crítica dos Baixos Valores de F1-Score e Recall	10
8	Etapa 7 - Regularização	11
8.1	Técnica Utilizada e Configuração	11
8.2	Discussão dos Resultados	11
9	Conclusão	12

1 Introdução

Este relatório apresenta o desenvolvimento de um pipeline de Machine Learning para a predição de Diabetes Mellitus utilizando o dataset *Diabetes Health Indicators* (BRFSS 2015 do CDC). O trabalho aborda classificação binária, classificação multiclasse e regressão usando redes neurais do tipo *Multi-Layer Perceptron* (MLP). Foram aplicadas técnicas de amostragem estratificada, seleção de atributos por Informação Mútua (*Mutual Information*), otimização de hiperparâmetros com o *Optuna* e regularização por *Early Stopping*. A análise foca nos impactos do desbalanceamento de classes nas métricas de avaliação e nos efeitos da redução de dimensionalidade no desempenho dos modelos.

2 Etapa 1 - Escolha e Análise do Dataset

O dataset escolhido é o **Diabetes Health Indicators Dataset**, obtido no Kaggle. Os dados vêm do *Behavioral Risk Factor Surveillance System* (BRFSS) de 2015, uma pesquisa telefônica realizada anualmente pelo CDC dos Estados Unidos. O conjunto foi selecionado por conter registros sobre fatores socioeconômicos e comportamentais associados ao diabetes, sendo bastante utilizado na literatura da área.

2.1 Características Estruturais

O arquivo original (*diabetes_binary_health_indicators_BRFSS2015.csv*) possui as seguintes especificações dimensionais primárias:

- **Quantidade Total de Amostras:** 253.680 registros estruturados.
- **Quantidade de Atributos Preditivos (Features):** 21 variáveis explicativas.
- **Variável Alvo (Target):** *Diabetes_binary*, indicando se o indivíduo é saudável (0.0) ou se possui diagnóstico prévio de diabetes ou pré-diabetes (1.0).

2.2 Distribuição de Classes e Problemas Identificados

A análise exploratória de dados revelou alguns pontos importantes que exigiram tratamento posterior:

- **Desbalanceamento de Classes:** A variável alvo é muito desbalanceada: 86,06% das amostras pertencem à classe 0 (saudável) e 13,94% à classe 1 (diabetes). Essa assimetria pode fazer com que o classificador priorize a classe majoritária.
- **Valores Ausentes e Outliers:** Não há dados ausentes no dataset. Como a maioria das colunas representa respostas discretas ou ordinais, a presença de outliers numéricos restringe-se à variável de IMC (BMI).

- **Duplicidade de Registros:** Foram identificadas 24.206 linhas duplicadas. Apesar de respostas idênticas serem possíveis em pesquisas de larga escala, optou-se pela remoção dessas duplicatas.
- **Correlação Elevada:** A correlação de Pearson (Figura 1) mostrou uma correlação linear baixa entre as variáveis de entrada e o alvo, o que justifica o uso de modelos capazes de capturar relações não-lineares, como as redes neurais.




Figura 1: Matriz de Correlação Linear de Pearson para os atributos do dataset.

3 Etapa 2 - Pré-processamento

Para treinar as redes MLP de forma eficiente, aplicou-se o seguinte fluxo de pré-processamento:

3.1 Amostragem Estratificada

Dado o tamanho do dataset (253.680 registros), o processo de treinamento repetido para busca de hiperparâmetros seria demorado. Assim, extraímos uma subamostra estratificada de 20% do total (50.736 linhas). A estratificação manteve a proporção original de 86,06% para a classe 0 e 13,94% para a classe 1.

3.2 Divisão em Treino e Teste (Holdout)

A subamostra foi dividida em:

- **80% para Treinamento:** Usado no ajuste de pesos da rede.
- **20% para Teste:** Reservado para a avaliação final do modelo com dados novos.

3.3 Padronização de Atributos

Como os algoritmos baseados em descida de gradiente são sensíveis à escala das variáveis, aplicou-se a padronização Z-score (**StandardScaler**) nas entradas. Isso transforma as features para terem média zero e variância unitária, evitando que atributos com valores maiores (como **BMI**) dominem o gradiente sobre atributos binários (como **Smoker**). O scaler foi ajustado no conjunto de treino e aplicado no teste para evitar vazamento de dados (*data leakage*).

4 Etapa 3 - Seleção de Atributos (Feature Selection)

Para reduzir o custo computacional e mitigar overfitting, aplicamos a seleção de atributos via **Informação Mútua (Mutual Information)**. Esse método avalia a relevância das variáveis independentemente do algoritmo de aprendizado.

A Informação Mútua mede a quantidade de informação compartilhada entre duas variáveis usando a Entropia de Shannon. Diferente do coeficiente de Pearson, ela consegue capturar dependências não-lineares, o que é útil para redes neurais.

Definimos um corte para selecionar os **10 atributos com maior relevância**. Variáveis como percepção geral de saúde (**GenHlth**), Pressão Alta (**HighBP**), Colesterol Elevado (**HighChol**) e Índice de Massa Corporal (**BMI**) ficaram no topo do ranking, condizendo com os principais fatores de risco conhecidos para o diabetes.

Em relação aos impactos dessa seleção (cujos resultados empíricos serão demonstrados na Etapa 4), observou-se que a redução de 21 para 10 atributos contribuiu positivamente em múltiplos aspectos: reduziu o **tempo de treinamento** por época quase pela metade devido à menor dimensão de entrada, mitigou o risco de **overfitting** eliminando ruídos e colunas correlacionadas, e melhorou a **interpretabilidade** do modelo ao focar estritamente nos 10 indicadores comportamentais mais relevantes, mantendo o **desempenho** geral estável em comparação com o uso de todas as variáveis.

5 Etapa 4 - Classificação com MLP

5.1 Classificação Binária

Como modelo *baseline*, configuramos uma rede **MLPClassifier** com hiperparâmetros iniciais fixos:

- **Arquitetura das Camadas Ocultas:** Duas camadas densas dispostas em formato piramidal com (64, 32) neurônios, respectivamente. Esta escolha justifica-se pela busca de extrair abstrações não-lineares progressivas a partir das variáveis de entrada. O design em formato de pirâmide (reduzindo a dimensão da camada 1

para a 2) atua como um compressor de características antes da camada de saída. Além disso, o número de neurônios (totalizando aproximadamente 3.000 parâmetros ajustáveis) previne o sobreajuste em relação ao tamanho da amostra, mantendo capacidade representativa.

- **Função de Ativação:** Unidade Linear Retificada (**relu**), minimizando o problema de desvanecimento do gradiente e acelerando o treino.
- **Algoritmo Otimizador:** adam, devido ao cálculo computacional adaptativo de taxas de aprendizado.
- **Taxa de Aprendizado Inicial:** 0,001 (padrão do *Scikit-Learn*), valor seguro que proporciona convergência estável na maioria das redes sem estourar gradientes.
- **Tamanho do Lote (Batch Size):** 128 instâncias por iteração.
- **Limitação de Épocas:** max_iter=150 iterações de salvaguarda.
- **Regularização Prematura:** Desativada temporariamente (**early_stopping=False**).

O experimento consistiu em comparar dois cenários:

1. **Cenário A (Todas as Features):** Alimentado com todos os 21 atributos originais.
2. **Cenário B (Features Seleccionadas):** Alimentado apenas com o subconjunto de 10 atributos via Informação Mútua.

As matrizes de confusão obtidas nos testes para ambos os cenários estão na Figura 2. As métricas detalhadas são comparadas na Tabela 1 na Etapa 6.

Matriz de Confusão - Todas_as_Features_Hiper_Ran

Real	0	7129	646
	1	1013	391
		0	1

(a) Cenário A - Todas as Features

Matriz de Confusão - Features_Seleccionadas_Hiper_R

Real	0	7482	293
	1	1134	270
		0	1

(b) Cenário B - Features Seleccionadas

Figura 2: Matrizes de Confusão para a MLP de Classificação Binária Baseline.




Figura 3: Evolução da Acurácia de Validação por Época para os modelos baseline binários (Cenários A e B).

A Figura 3 apresenta a evolução da acurácia de validação ao longo das épocas de treinamento para os dois cenários. Em ambos os casos, a acurácia de validação sobe rapidamente nas primeiras épocas e se estabiliza em valores próximos a 84–85%, confirmando a convergência dos modelos dentro do limite de 150 iterações. A estabilidade da curva ao longo das últimas épocas indica que o modelo não se beneficiaria de um treinamento mais longo sem ajustes adicionais de hiperparâmetros.


5.2 Classificação Multiclasse

Para estender a análise, avaliamos a classificação de 3 classes usando o arquivo *diabetes_012_health_indicators_BRFSS2015.csv*, onde a variável alvo *Diabetes_012* indica se o indivíduo é saudável (0.0), pré-diabético (1.0) ou diabético (2.0).


O pré-processamento (holdout 80/20, amostragem de 20% e padronização) e os 10 atributos de entrada foram mantidos. A *MLPClassifier* foi configurada com a mesma estrutura de camadas (64, 32), ativação *relu* e otimizador *adam*.

A avaliação do modelo nos dados de teste gerou as seguintes métricas macro-ponderadas:

- **Acurácia Global:** 0,8353
- **Precisão Macro:** 0,4730
- **Recall Macro:** 0,3814
- **F1-Score Macro:** 0,3882



(a) Matriz de Confusão Multiclasse



(b) Curva de Aprendizado (Multiclasse)

Figura 4: Resultados obtidos para a MLP na tarefa de Classificação Multiclasse.

A análise da matriz de confusão (Figura 4a) revela que o modelo apresenta grande facilidade para classificar corretamente indivíduos saudáveis (Classe 0), porém exibe dificuldades agudas na identificação das classes 1 (pré-diabetes) e 2 (diabetes). Essa dificuldade é explicada pelo desbalanceamento severo das classes: a classe 1 representa uma fração extremamente ínfima do conjunto de dados original (cerca de 1,8%), fazendo com que o classificador praticamente ignore essa classe em suas predições e a confunda constantemente com as classes adjacentes. Isso prejudica o *Recall* e a *Precisão* macro-ponderados. A curva de perda (Figura 4b) aponta uma convergência estável da rede até o limite de 150 épocas.

6 Etapa 5 - Regressão com MLP

Adaptamos o pipeline para uma tarefa de regressão usando a classe `MLPRegressor`.

6.1 Configuração da Meta Contínua

A variável contínua BMI (**Índice de Massa Corporal**) foi removida do conjunto de entradas e redefinida como a nova variável alvo numérica contínua (y_{reg}). O objetivo da rede neural passou a ser a estimativa exata do IMC de um indivíduo a partir de seus demais hábitos comportamentais e indicadores clínicos (excluindo a coluna `Diabetes_binary`). Para manter o alinhamento com a Etapa 3, o regressor foi alimentado utilizando o ranking de atributos selecionados (excetuando o próprio alvo). Os parâmetros estruturais de camadas ocultas (64,32), otimizador `adam`, ativação `relu` e `batch_size=128` foram preservados de forma intencional para manter a consistência metodológica, permitindo uma comparação direta da capacidade de generalização e do comportamento de aprendizado da mesma arquitetura de rede neural em tarefas de natureza distinta (classificação vs. regressão).

6.2 Resultados e Análise Crítica

A avaliação do regressor em dados de teste inéditos gerou os seguintes resultados numéricos estáveis:

- **Erro Médio Absoluto (MAE):** 4,4532
- **Erro Quadrático Médio (MSE):** 40,9024
- **Raiz do Erro Quadrático Médio (RMSE):** 6,3955
- **Coefficiente de Determinação (R^2 Score):** 0,1182

O comportamento do regressor (valores reais vs. preditos e a distribuição dos resíduos) está plotado graficamente na Figura 5. A análise das métricas indica que, em média, as estimativas da MLP desviam-se por aproximadamente 4,45 pontos de IMC. O fato de o RMSE (6,3955) apresentar-se superior ao MAE (4,4532) mostra que o modelo comete erros de maior magnitude nas caudas da distribuição, demonstrando dificuldade para prever o IMC de indivíduos em extremos de peso.

O coeficiente $R^2 = 0,1182$ indica que as features de saúde disponíveis explicam apenas 11,82% da variabilidade total do IMC. Isso reflete a complexidade do problema: fatores biológicos e comportamentais cruciais para a definição do IMC, tais como a taxa metabólica basal, o consumo calórico preciso e rotinas específicas de atividade física, não estão presentes no questionário do BRFSS, limitando o desempenho final do modelo. A evolução convergente do erro de regressão pode ser monitorada no subgráfico correspondente.




Figura 5: Resultados gráficos obtidos na Etapa 5 (Regressão).

7 Etapa 6 - Otimização de Hiperparâmetros

Retornando ao escopo da Classificação Binária, utilizamos o framework **Optuna** para buscar melhores hiperparâmetros. O foco na classificação binária se deu pelas baixas taxas de Recall observadas nas redes baseline da Etapa 4, causadas pelo desbalanceamento.

7.1 Estratégia do Espaço de Busca e Função Objetivo

O Optuna utilizou amostragem bayesiana (algoritmo TPE) em 10 trials no seguinte espaço dinâmico:

- Neurônios na Camada Oculta 1: Inteiros entre 32 e 128 (passo de 32).
- Neurônios na Camada Oculta 2: Inteiros entre 16 e 64 (passo de 16).
- Função de Ativação: Alternância entre `relu` e `tanh`.
- Taxa de Aprendizado Inicial (α): Escala logarítmica contínua entre 10^{-4} e 10^{-2} .
- Tamanho do Lote (*Batch Size*): Escolha categórica entre [64, 128, 256].

A função objetivo buscou maximizar o F1-Score no conjunto de validação para forçar a rede a reduzir falsos negativos. Após os 10 trials, o **melhor F1-Score obtido na validação foi de 0,3144**. O conjunto de hiperparâmetros que maximizou essa métrica foi:

- **Neurônios na Camada 1:** 128
- **Neurônios na Camada 2:** 16
- **Função de Ativação:** `tanh`
- **Taxa de Aprendizado Inicial:** 0,007279
- **Tamanho do Lote:** 256

O classificador final otimizado foi reavaliado e sua matriz de confusão correspondente gerada (Figura 6).

Em relação ao **impacto no tempo de treinamento**, o processo exploratório do Optuna (com 10 *trials*) elevou o custo computacional provisoriamente, exigindo o treinamento completo de 10 arquiteturas distintas. Contudo, para o modelo final otimizado, o aumento do tamanho do lote (*batch size*) de 128 para 256 reduziu o número de atualizações de peso por época, acelerando discretamente o tempo de treinamento iterativo em comparação com a rede *baseline*.




Figura 6: Matriz de Confusão do modelo MLP Otimizado via Optuna.

7.2 Tabela Comparativa Geral do Pipeline

A Tabela 1 consolida o desempenho evolutivo observado ao longo do projeto para a classificação binária, incluindo os dados obtidos após a aplicação de regularização discutidos na seção seguinte.

Tabela 1: Métricas Comparativas de Desempenho (Classificação Binária).

Cenário / Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Todas_as_Features_Hiper_Random	0,819261	0,377049	0,278490	0,320361	0,750299
Features_Selecionadas_Hiper_Random	0,844536	0,479574	0,192308	0,274530	0,775117
MLP Otimizada (Optuna)	0,847587	0,505112	0,175926	0,260961	0,794098
MLP Regularizada (Early Stopping)	0,850746	0,552469	0,127493	0,207176	0,802013

7.3 Análise Crítica dos Baixos Valores de F1-Score e Recall

A Tabela 1 mostra que, enquanto a acurácia é alta (entre 81,9% e 85,1%), as métricas que avaliam a classe positiva (Recall e F1-Score) são baixas.

Isso ocorre porque apenas 13,94% dos dados são positivos. O classificador tende a focar na classe majoritária para reduzir o erro global. Como consequência:

1. **A Ilusão da Acurácia:** Um modelo simples que apenas classificasse todos como saudáveis (classe 0) obteria cerca de 86% de acurácia. Por isso, os altos valores de acurácia observados não refletem eficácia clínica, mas sim o peso estatístico da classe majoritária.
2. **Subestimação do Recall (Sensibilidade):** O Recall variou entre 12,7% e 17,6% nos modelos otimizados e regularizados. Isso significa que a rede identifica apenas cerca de 1 em cada 6 ou 8 diabéticos, gerando muitos falsos negativos.
3. **A Queda Consequente do F1-Score:** Como o F1-Score é a média harmônica entre Precision e Recall, ele é puxado para baixo pelo baixo Recall, limitando-se ao teto de 0,2610 (atingido pelo Optuna).

4. **A Importância do ROC-AUC:** O ROC-AUC manteve-se estável, alcançando 0,8020 no modelo com Early Stopping. O ROC-AUC avalia a ordenação probabilística do classificador. O valor próximo a 0,80 indica que a rede aprendeu a ordenar bem as probabilidades, mas o limiar de decisão de 0,5 prejudica a classificação.

Para aplicações clínicas, contornar esses limites exigiria ajustar o threshold de decisão via curvas ROC, usar pesos nas classes (*class weights*) na função de perda, ou aplicar algoritmos de sobreamostragem (como o *SMOTE*).

8 Etapa 7 - Regularização

A etapa final consistiu na aplicação de técnicas de regularização, comparando o comportamento da rede com os cenários anteriores.

8.1 Técnica Utilizada e Configuração

A abordagem de regularização incorporada ao projeto foi o **Early Stopping (Parada Antecipada)**. O algoritmo separa 15% dos dados de treino para validação. Se a perda ou a acurácia de validação não melhorar por 10 épocas seguidas, o treino é interrompido para evitar overfitting.




Figura 7: Curvas de Aprendizado para os cenários Otimizado sem Regularização e com Early Stopping.

A Figura 7 ilustra os gráficos de monitoramento. Sem regularização, a perda de treino cai constantemente até o limite de épocas. Com Early Stopping, o treino é interrompido antes das 150 épocas quando a curva de validação (tracejado laranja) atinge estabilidade.

8.2 Discussão dos Resultados

A análise das curvas mostra que o treinamento convergiu de forma estável e que a Informação Mútua reduziu a complexidade, favorecendo a generalização.

No conjunto de teste, o modelo com Early Stopping teve um aumento de precisão, que subiu de 50,5% para **55,2%**, e de ROC-AUC, que chegou a **0,8020**. O Recall caiu

para 12,7% (com F1 de 0,2072), mas o modelo final se mostrou mais robusto contra falsos positivos, indicando que a parada antecipada barrou ajustes espúrios.

Análise de Overfitting e Underfitting

1. **A rede apresentou sinais de overfitting?** Sinais leves de overfitting foram observados no modelo sem regularização: a loss de treino continuava caindo enquanto a perda de validação estagnou, indicando que a rede começava a se ajustar aos dados de treino além do necessário. O Early Stopping suprimiu esse comportamento.
2. **Qual técnica de regularização foi utilizada?** Early Stopping (Parada Antecipada), com `validation_fraction=0.15` e `n_iter_no_change=10`.
3. **Houve melhoria no desempenho em dados não vistos?** Sim. A Precisão subiu de 50,5% para 55,2% e o ROC-AUC aumentou de 0,7941 para 0,8020, indicando melhor capacidade de generalização.
4. **Qual estratégia apresentou melhor equilíbrio entre desempenho e generalização?** A combinação de seleção de atributos por Informação Mútua, otimização de hiperparâmetros com Optuna e regularização por Early Stopping.

Análise de Underfitting: Os modelos não apresentaram sinais de underfitting. A curva de loss de treino converge de forma contínua e decrescente até estabilizar, sem platô prematuro nas primeiras épocas. Ademais, as métricas de treino (especialmente o ROC-AUC) superam consistentemente as de validação, comportamento característico de ajuste adequado e não de subajuste. A arquitetura (64,32) possui capacidade representativa suficiente para o tamanho e a complexidade do dataset BRFSS 2015.

Considerando os resultados, o melhor equilíbrio entre desempenho e generalização foi alcançado pela combinação de seleção de atributos por Informação Mútua, otimização de hiperparâmetros com Optuna e regularização por Early Stopping.

9 Conclusão

O pipeline desenvolvido cumpriu os requisitos propostos. O estudo confirmou que a acurácia isolada é insuficiente para problemas biomédicos desbalanceados e provou que o gerenciamento correto da dimensionalidade e o ajuste fino de parâmetros via Early Stopping e Optuna ajudam a obter redes neurais mais robustas e generalistas.